

PhysicalAIのトレンド

 松尾・岩澤研究室
MATSUO-IWASAWA LAB UTOKYO

2026/1/29

松尾・岩澤研究室 特任助教

河野 慎



※NNによるE2E, ただしレーンキープのみでレーンチェンジは人手

今の自動運転の最先端: SimLingo (英Wayve)



2016年頃当時最新のロボティクス(2足歩行, Boston Dynamics)




今のロボティクスの最先端(Boston Dynamics)



Physical AI = ??



環境





自動運転



・「横断歩行者がいる」
→「減速・停止すべき」
・「制限速度25mph」
→「追従速度を下げる」



ロボティクス




・「左アームが持つ錠に
右アームが持つ鍵をさす」



自動運転・ロボティクスともに同じ構造を持つ制御システム=PhysicalAI

補足: Webエージェント(Web環境に特化したAIエージェント)


- Physical AIの制御構造はWebエージェントにも現れている
- 例) OpenAI Computer Use AI



補足: Webエージェント(Web環境に特化したAIエージェント)




- Physical AIの制御構造はWebエージェントにも現れている
- 例) OpenAI Computer Use AI



補足: Webエージェント(Web環境に特化したAIエージェント)




- Physical AIの制御構造はWebエージェントにも現れている
- 例) OpenAI Computer Use AI



補足: Webエージェント(Web環境に特化したAIエージェント)

- Physical AIの制御構造はWebエージェントにも現れている
- 例) OpenAI Computer Use AI



Physical AIの最新の状況と今後の展望について, 自動運転を例にしながら解説

- 1. 自動運転・ロボティクスに共通する制御構造
- 2. これまでの自動運転: モジュール型からE2Eへ
- 3. Vision-Language-Action モデル(VLA)
- 4. 世界モデルによる計画と予測
- 5. 世界モデルを取り入れた基盤モデル
- 6. Physical AIとしての今後の展望

免責: 技術的な詳細は触れないので, 気になった方は後で質問していただけると多少説明できます

Physical AIの最新の状況と今後の展望について, 自動運転を例にしながら解説


- 1. 自動運転・ロボティクスに共通する制御構造
- 2. これまでの自動運転: モジュール型からE2Eへ
- 3. Vision-Language-Action モデル(VLA)
- 4. 世界モデルによる計画と予測
- 5. 世界モデルを取り入れた基盤モデル
- 6. Physical AIとしての今後の展望

免責：技術的な詳細は触れないので, 気になった方は後で質問していただけると多少説明できます

これまでの自動運転技術(Autonomy 1.0)

- スタック型: 基本的にモジュールを分けて, 繋げて構成されている

例: TIERIV社で開発されているAutoware



2. 認識モジュール

- 車両・歩行者の検出
- 検出結果の追跡
- 将来予測

1. データ収集

- カメラ: 画像
- LiDAR: 点群
- レーダー: 点群

4. 制御モジュール

- 計画をもとに車体制御

3. 計画モジュール

- 認識結果をもとに行動計画をする


- 自車の周囲の環境を理解するため, 交通参加者を検出する



- カメラ画像ベースの検出モデル



- YOLOX[G.Zheng+ 2021]



- LiDAR点群ベースの検出モデル




- CenterPoint[T.Yin+2020]

明示的に何を認識しているかわかるため, 扱いやすい

- 認識した交通参加者が今後どう動くか予測する


現時刻から大体**3-7**秒先まで予測する



予測した経路

検出した車両

ルールベース (数理モデル)



MTR [S. Shaoshuai+ 2022]

予測結果の解釈もしやすく, 制御しやすい




- いわゆる“普通の”深層学習ベースの手法がメイン
 - ✓ モデル自体はCNNベースが多く, 高速に推論が可能
 - CNNアーキテクチャが中心だが, Transformerベースも存在
 - ✓ モジュールごとに交換が可能
 - より性能が高いモデルに改良
 - ✗ 汎化性能があまり高くない
 - 分布外に弱く, 転移学習などの工夫が必要
 - ✗ 前段のモジュールを交換した場合, 後段のモジュールは再学習が必要
 - いわゆるドメインシフトが起きてしまうため

- Autonomy 1.0ではスケール(=普及)しづらい
 - 事前に想定していない走行環境や交通状況に対応できない
 - 想定外に対しては学習ではなく実装で吸収せざるを得ない
 - モジュールの一部を修正すると, 全体の再学習や再検証につながる
 - モジュール分割による局所改善・独立検証という利点を享受できない
- 安全性の根拠が現状, 人手による分解・ルールに依存している
 - LiDARやHDマップなど比較的高価な要素に依存している


スケールするためには, 設計思想から捉え直す必要があった

Autonomy 1.0 → Autonomy 2.0



- E2E自動運転(=一つのNNで走行)のメリット
 - 均一的な計算処理
 - モジュール毎に個別最適化する必要がない
 - データを通した汎化
 - 異なる車体/センサ構成/地域に対して, 学習によって対応が可能
 - 拡張性があり経済的である
 - HDマップのような高価なデータは必要なく, 安価なセンサで済む
 - より安全な自動走行
 - 人手で設計した走行ルールより優れる(=ヒューマンエラーがない)

- 世界でE2E自動運転技術と呼ばれているものの多くはこのタイプ
 - 各機能において研究されていたTransformerベースのモデルを連結
 - 全モジュールで共通のBird's eye view(鳥瞰図)特徴量を抽出
 - 各モジュールで必要なクエリを用いて, マルチタスク学習させる



依然としてタスク設計に強く依存している形

Physical AIの最新の状況と今後の展望について, 自動運転を例にしながら解説

- 1. 自動運転・ロボティクスに共通する制御構造
- 2. これまでの自動運転: モジュール型からE2Eへ
- 3. Vision-Language-Action モデル(VLA)
- 4. 世界モデルによる計画と予測
- 5. 世界モデルを取り入れた基盤モデル
- 6. Physical AIとしての今後の展望

免責: 技術的な詳細は触れないので, 気になった方は後で質問していただけると多少説明できます


基盤モデル(大規模言語モデルや生成AI)の登場

- 大量のデータの学習による汎用的な知識・表現の獲得
 - 自己教師あり学習 x Transformerアーキテクチャによるスケール則
- 基盤モデルの様々な下流タスクに対する汎用性の高さ
 - プロンプトの調整による汎用的な使い方・推論による意思決定(CoTなど)
- Stable Diffusionをはじめとした高解像度・詳細な動画生成技術
 - 観測と行動から次を予測する世界モデル実現への期待

自動運転技術にも活用できないか？という発想

自動運転分野における基盤モデル


- 2023年以降, 基盤モデル研究が**自動運転文脈**にも派生



※独断と偏見に基づく/漏れはいっぱいあります. [参考] <https://github.com/LMD0311/Awesome-World-Model?tab=readme-ov-file>

自動運転分野における基盤モデル

- ブームは去るところか盛り上がっていている
 - 2024年が約60本に対し, 2025年は約90本
 - Awesome-WorldModel for ADベース
- <https://github.com/LMD0311/Awesome-World-Model>



2024年


2025年



- なぜLLM/VLMは汎用的な知識が獲得できているのか？

世界の知識そのもの


例: 「春は桜が綺麗」の事前学習 → 「春」「桜」「綺麗」の間に強い関係性がある



- Geminiをfine-tuningする形で軌道計画を出力する


所望の出力も全てテキスト形式にして, fine-tuningすることで実現

$$O_{trajectory} = \{(x_t, y_t)\}_{t=1}^T, T_{intent} = \text{text}(\text{"Turn right"})$$
$$O_{trajectory} = \mathcal{G}(T_{intent}, T_{ego}, V)$$



- 2025年11月に公開されたVLAモデル

推論コードと重みは公開されており, 検証することが可能




基本VLM+行動を出力するモジュールの追加

- 画像データと指示文(+ナビ文)からCoT
- 経路をFlow-Matchingで出力

Chain of Causationというタスクを設計

- 従来のCoTデータセットは因果関係が微妙
 - 行動の説明が曖昧
 - 意思決定に直接関係がない説明
 - "その観測時には"わからない因果

- オープンVLMをベースに自動運転用に改良を加えたVLAモデル




- 3種類のタスクを解かせる

Vision-Language Understanding

VQA

Commentary



"Q: Does the ego vehicle need to change lanes or deviate from the lane center due to an upcoming instruction?"
"GT A: The ego vehicle must change to the left lane to circumvent the bicycle."
"Pred A: The ego vehicle must transition to the left lane to avoid the bicycle."

"Q: What should the ego vehicle do based on the traffic light?"
"GT A: Based on the green traffic light the ego vehicle can accelerate and continue driving but should pay attention to the vehicle in front and adjust its speed accordingly."
"Pred A: The ego vehicle can keep its pace and continue driving, given the green traffic light."

"Follow the route. Stay in the same spot due to the red traffic light."

"Follow the route. Slow the vehicle to stay at the rear of the yellow car that is to the front."

"Follow the route. Stay stationary due to the pedestrian crossing your line of travel."

- タスク1: 運転の軌跡を正しく出力
 - 様々な状況で正しく経路を出力
- タスク2: VQAとコメントリ
 - 行動とその理由説明
 - 言語空間から行動空間へCoT
 - 自車はどうすべきか？なぜか？




- タスク3: Action Dreaming

- 同一の画像に対して指示と経路を合成し、ルールベースで安全/危険をアノテーション
- 学習を通して、画像だけに頼らない行動の実行拒否をできるようにする

最新のWayveによるE2E状況 [2025/12/17]


- ・ 汎化性能の検証目的に, 500都市で走行テスト

2025: New Cities x Time




- 最近のトレンドとしては, 画像生成技術である拡散モデルを応用

「滑らかなデータを生成することができる」性質が行動生成に適合する



- VLA + 強化学習によって実現している

LLMにおいても, SFT + RLHFによって性能が劇的に良くなった(DeepSeek-R1)





Physical AIの最新の状況と今後の展望について, 自動運転を例にしながら解説

- 1. 自動運転・ロボティクスに共通する制御構造
- 2. これまでの自動運転: モジュール型からE2Eへ
- 3. Vision-Language-Action モデル(VLA)
- 4. 世界モデルによる計画と予測
- 5. 世界モデルを取り入れた基盤モデル
- 6. Physical AIとしての今後の展望

免責：技術的な詳細は触れないので, 気になった方は後で質問していただけると多少説明できます

世界モデル = 観測された情報に基づいて世界の構造を学習するモデル



世界モデル = 観測された情報に基づいて世界の構造を学習するモデル



世界モデル = 観測された情報に基づいて世界の構造を学習するモデル



世界モデル = 観測された情報に基づいて世界の構造を学習するモデル

観測情報から,

1. 正しく**未来を予想(測)**し,
2. 予想をもとに行動する



世界モデルの入出力



- PhysicalAIにおける世界モデルは, 2つの役割が期待される

1. 知覚と理解(Implicit Representations)


- 認識と予測モジュールにおいて, 外部環境を理解することは重要
- →(前述の)VLAが活用され始めている

2. シミュレーションと将来予測(Future Predictions)


- マルチモーダルな入力(画像、点群、軌跡、言語など)に基づいた世界を予測
- →評価的な使い方およびデータ生成への使い方
 - 幾何学的な正しさ
 - 実世界ダイナミクス

自動運転向けの基盤モデルにおけるスケール側

- (当然ではあるが)もれなくデータとモデルサイズ両方とも多い方が良い




- GAIA-1でモデルのスケール則が確認されている
- 実験的にもデータを多様にすると性能が上がる




いかにして, 多様なデータを作るか?
→ **世界モデルのポテンシャル**にかかっている


- エッジケースにおける実世界の動きを捉えたい




- エッジケースにおける実世界の動きを捉えたい



- 英Wayveによる世界モデル→当時パイオニアとなったモデル



- 自己回帰型をやめて，拡散モデルベースで統一
 - 高解像度 + マルチカメラの一貫性のある動画の生成が実現



GAIA-3 [Wayve, 2025/12]

- GAIA-2をさらにスケール拡大 => 精密かつ一貫性が向上
 - パラメータ数: 2倍の15B
 - データ数: 10倍(具体的には明記なし, 9か国・3大陸)
 - 計算機環境: 約5倍




Physical AIの最新の状況と今後の展望について, 自動運転を例にしながら解説


- 1. 自動運転・ロボティクスに共通する制御構造
- 2. これまでの自動運転: モジュール型からE2Eへ
- 3. Vision-Language-Action モデル(VLA)
- 4. 世界モデルによる計画と予測
- 5. 世界モデルを取り入れた基盤モデル
- 6. Physical AIとしての今後の展望

免責: 技術的な詳細は触れないので, 気になった方は後で質問していただけると多少説明できます

- Visual Chain-of Thoughtを利用したVLAモデル




- 指示から, **目標の状態**画像を予測
- アクショントークンは非自己回帰出力




- VLM => 動画生成と行動予測の同時学習

思想はCoT-VLAに似ているが、設計は異なる




⚡ 动态操作



InternVLA-A1 在高度动态的场景中展现出卓越的鲁棒性。


🧸 日常任务



1x WorldModel [1X, 2026/1]

- 世界モデルの出力結果から逆動力学で行動を決定

生成された動画が正しければ正しいほど、適切な行動が可能となる



Physical AIの最新の状況と今後の展望について, 自動運転を例にしながら解説

- 1. 自動運転・ロボティクスに共通する制御構造
- 2. これまでの自動運転:モジュール型からE2Eへ
- 3. Vision-Language-Action モデル(VLA)
- 4. 世界モデルによる計画と予測
- 5.世界モデルを取り入れた基盤モデル
- 6. Physical AIとしての今後の展望

免責：技術的な詳細は触れないので, 気になった方は後で質問していただけると多少説明できます

自動運転・ロボティクスもスケール競争に入りつつある

自動運転(参考:Alpamayo-R1)

- データ量:80,000時間, 25カ国・1,700都市
 - 国内事例:Turing社で80時間以上の実走行データでデータセット構築
- モデルサイズ:0.5B~7B相当※


ロボティクス(参考:InternVLAや π シリーズ)

- データ量: 大体7-8000時間~10000時間
 - 国内事例:AIRoAで94時間以上の操作データでデータセット構築
- モデルサイズ:2B~5B相当※

※GPU目安:7B相当ならば, H200×32枚くらいあると開発が可能

自動運転とロボティクスの違い

コアとなる技術は一緒だが、問題設定と制約条件が本質的に異なる



- 現状, VLAと世界モデル(DM)による共創は(少なくとも)PAIではまだない
基礎研究レベルでは混ぜるとうまくいく研究は出始めている
特にゲーム領域では世界モデルをうまく使っている研究は多い
Dreamer4やGenie3など
- Physical AIの推論に世界モデルは使えるのだろうか？
現在の主流は, 「VLM => VLA」: 言語学習で獲得した知識を利活用した行動計画
ここ数ヶ月で「DM => VAM」: 動画学習で獲得した知識を利活用した行動計画

- Physical AIとは, 実空間で観測→認識→判断→行動をするシステム

自動運転もロボティクスも(Webエージェントも)共通の技術で研究・開発されている

VLMやDMなどの基盤モデルを中枢に据えたE2Eシステム

=>人間が考えるPAIに必要な知識を獲得させるのが重要？

様々な環境により特化させていくところは今から

「世界モデル」という概念が使われた技術が2025年の夏頃から急激に出てきている

その性能も急激に改善傾向

VLM/DMいずれも大規模データ・大規模計算資源がマスト

2026年はPhysical AIが飛躍する年になる(かも)

- Autonomy1.0/2.0両方において, 自動運転技術の安全性の評価は重要
安全かわからない車両を公道で走らせるわけにはいかない
走行環境を模擬した**シミュレーション環境**で検証することが一般的
- 実際に走行する実環境を想定したシミュレータを人手で作成



<https://qiita.com/ttanaka3/items/6ae5f8331d60b0454308>より引用

- 時間的にも金銭的にも膨大なコストがかかる
 - Unityベースで実環境ライクな空間を作成
 - 交通参加者アセットを増やす



データ学習によるシミュレータ環境が必要


自動運転におけるシーン再構成の難しさ

- 幾何学的な正しさ: 3D Computer Vision分野の領域


NeRFやGaussian Splatting…異なる画像を重ね合わせ空間を再構成



- 自動運転車にはほぼ必ず車載カメラがあるため、適用は容易に思える



(a) NeRFs camera settings



(b) Ego car camera settings


- 車載カメラの特徴

- 各カメラ間の重なりは少ない
- 自他車両ともに高速に動く & 動的な物体が多い
- 閉じられた空間ではない(屋内ではない)

既存のNeRF/3DGS手法は適用が難しく、自動運転専用設計が必要

自動運転におけるニューラルレンダリング技術

- NeRFを皮切りに普及→Gaussian Splattingが主流に



※独断と偏見に基づく/漏れはいっぱいあります


- 車載映像の再構成結果



実際の走行映像




再構成結果




走行データ

車両や歩行者などを除去しており, 任意の配置が可能

- LiDARの点群データを再構成した結果



- 再構成した空間において、物体検出を適用した結果



お台場のシミュレータ空間[w/TIERIV, 2024]

- 車を動的に配置可能に拡張



再構成



GT


再構成(車変更)

再構成時の深度

Ghost Gym[Wayve, 2023]



- Wayveでも同様の仕組みを作っている



- 2026年度人工知能学会全国大会@ 群馬 6/8-12で
オーガナイズドセッション「基盤モデル時代のPhysical AI」を開催します！

- PhysicalAI周りは海外企業がリード
- 開示される情報は一部となっている



基盤モデルが普及した際のPhysical AIの
あり方や知見の共有および議論を行い、
Physical AIの実用化を加速させる

OS-47 基盤モデル時代におけるPhysical AI

オーガナイザ

- 河野 慎（東京大学/ZEN大学）
- 松嶋 達也（東京大学/AIRoA）
- 河原塚 健人（東京大学）
- 太田 佳（AIRoA）
- 尾形 哲也（早稲田大学/AIRoA）

- ご都合がよければぜひ聴講にいらしてください！