





THE DATA SCIENCE BOOKLET

The problem:

データサイエンスとは何なのか?

データサイエンスという言葉は厳密な定義があるわけではなく、正確な表現をすることを目的とするならば、正しく説明することは非常に難しくなります。多くの記事は広範な解釈ができるように書かれていることから、厳密な定義は難しいと言えるでしょう。ですが、事実としてデータサイエンスという言葉は、コンピューター技術の発展などによってその存在感を増しています。

25年前におけるデータサイエンスは、データを集め、それを統計学上の手法に当てはめるというものでした。今日、データサイエンスはその対象とする領域を広げており、データ分析、予測分析、データマイニング、ビジネスインテリジェンス、機械学習、ディープラーニングといった分野においても使われるようになっていきます。



The solution:

本ブックレットは、データサイエンスとその周辺領域において聞く可能性がある言葉を集め、分かりやすく整理することを目的としています。

ですので、本ブックレットではそれぞれの言葉がデータサイエンスという大きな絵の中でどこに位置するのかということを時間軸も踏まえた上で説明していきます。

今回このようなブックレットを準備した理由は、データサイエンティストへの道を歩みはじめるにあたり、進んでいく道を少しでも明確にするためです。



コンテンツ

LET'S BREAK THINGS DOWN

1. データサイエンスにおけるデータ

- データに対して何をするのか
(ビッグデータと従来のデータ)
- データがどこから来るのか
- 誰がデータを扱うのか


2. 過去を分析するデータサイエンス

- ビジネスインテリジェンスが行うこと
- どこでビジネスインテリジェンスが使われるか
- 誰がデータサイエンスのBIを担うか

3. 未来を予測するデータサイエンス

従来の手法

- 将来を予測する従来の手法
- どこでその手法が使われるか
- 誰が従来の手法を使うのか



コンテンツ

(続き)


4. 未来を予測するデータサイエンス 機械学習



- データサイエンスにおける機械学習とは
- どこで機械学習が適用されるのか
- 誰が機械学習を使うのか

5. データサイエンスにおけるプログラミング言語

6. データサイエンスにおけるソフトウェア

7. よくある質問





データ

従来のデータ

データはデータサイエンスにおける基礎となります。つまり、データは全ての分析における基礎であるということです。データサイエンスという観点で考えると、データには従来のデータとビッグデータの二種類があります。

従来のデータは、データベースなどを通じ、一つのコンピューターに保存されているデータのことであり、数字や文字列といった形でテーブルとして保存されています。

ここで、従来のデータという用語は一般的に使われている言葉ではありません。従来のデータは、ビッグデータとの対比という意味においてその違いを明確にするという意味合いにおいて用いられている言葉です。




ビッグデータ

ビッグデータは従来のデータよりも大きなデータと
言うことができますが、単純に量が多いだけではあ
りません。そして、ビッグデータは複数のコン
ピューターにまたがって存在することが一般的です。

ビッグデータは、しばしばVというアルファベット
によって表現されます。そして、このVはより具体
的には**ビッグデータの3V**などと言われています。

- Variety（多様性） – 数、文字列だけではなく、画
像、音声といったデータもビッグデータを構成
する要素となります。
- Velocity（速さ） – ビッグデータはリアルタイム
で処理されることも多々あります。
- Volume（量） – ビッグデータは、エクサバイト
（1テラバイトの100万倍）といった容量になるこ
ともあります。





データに対して何をするのか



Before the answer... **CONSIDER THIS**

今のシナリオを考えてみましょう：あなたは
大企業のデータサイエンティストであり、
上司があなたに以下の指示をしました：

“我々は次の四半期の顧客満足度について意識を向ける必要があるので、解約率を予測したい。なので、そのプロセスをまとめておいてほしい”

OR

“我々は前の四半期に関して十分な顧客データがある。このデータを使って次の四半期の解約率を予測することはできるだろうか？”

右の二つの
シナリオを読み、
それぞれの違い
について考えて
みましょう



Before the answer... **CONSIDER THIS**

今のシナリオを考えてみましょう：あなたは
大企業のデータサイエンティストであり、上
司があなたに以下の指示をしました：

“我々は次の四半期の顧客満足度について意識を向ける必要があるので、解約率を予測したい。なので、そのプロセスをまとめておいてほしい”

“我々は前の四半期に関して十分な顧客データがある。このデータを使って次の四半期の解約率を予測することはできるだろうか？”

データなし

データあり


前処理



データサイエンスの準備

データサイエンティストが自らデータを集めたか、外部から持ってきたのかに関係なく、まず収集されたデータはそのままの状態で作保存されます。このデータは、調査によって得る場合もあれば、ブラウザのクッキーで半自動的に取得できる場合もあります。

生データは加工していないデータのことであり、より分かりやすく、かつ分析しやすい形に処理する必要があります。

そして、データを処理する手続きのことを総称して**前処理**と呼びます。





前処理


一般的な手順

観測データのクラスラベリング

データのラベリングとは、データをカテゴリやラベル付けすることをいい、。その対象は従来のデータであれば量的/カテゴリデータ、ビッグデータでは画像やオーディオデータとなります。

データクレンジング

欠けた値や、スペルミスなどがあるデータを修正することをデータクレンジングと言います。




前処理

一般的な手順

データのバランシング

グループに分けたデータの中に均等ではない何らかのバイアス（意図しない秩序）が入ってしまった場合、そのデータは母集団の代表性を満たさないと言えます。

そういった場合には母集団から均等にデータをもってくるといったことを行いますが、その手法のことをデータのバランシングと言います。



前処理

一般的な手順

データのシャッフル

データの順番を変えて、データの中に予期せぬ秩序が入ってしまうことを防ぐことため、データのシャッフルを行うことがあります。


例えば、あるウェブサイトを利用したデータを取ってきた場合、最初に訪問をした100のデータを取ってくることはランダム性を満たしているとは言えませんので、データをシャッフルする必要があります。



前処理

一般的な手順

データマスキング(ビッグデータ)

得た情報に秘匿性が含まれており、そのデータが外部に漏れたり、特定の人物を特定できてしまう可能性がある場合、データマスキングという手法を用いて、もとのデータから秘匿性がある内容を取り除いたり、情報源を特定することができないようにします。この手法は従来のデータでも適用され得ますが、基本的にはビッグデータが対象となります。





データはどこから来るのか

データはどこから来るのか



従来のデータ

従来のデータの例としては、顧客情報や過去の株価といったものがあげられます。

顧客情報は、顧客ID、その顧客が何回問い合わせをしてきたのか、一回の購買でいくら使ったのか、住所はどこか、電話番号は何か、といった情報から構成されることになります。

過去の株価は、過去のある期間や、あるタイミングにおける株価の情報となります。







データはどこからくるのか？

ビッグデータ

継続的に成長している企業は、ビッグデータを自ら作り、それを活用しています。例えば、Facebook、Google、LinkedInといった企業はビッグデータを活用しています。産業用の設備に備わっているセンサーから得られたデータもビッグデータを構成する要素となります。

今日では、ゼタバイトという巨大なデータが存在していると言われています。こちらのリンクをクリックすると、現時点で存在するデータ量を確認することができます



誰がデータを扱うのか

誰がデータを扱うのか

データアーキテクトと データエンジニア

データベースの作成と共に、生データを扱ってデータの前処理などを行い、それらのデータを管理する人をデータの専門家と呼びます。その肩書から、それぞれ同じように感じるかもしれませんが、その職能は異なります。

データアーキテクト と データエンジニア (ビッグデータアーキテクトとビッグデータエンジニアを含みます) はデータサイエンスの市場において欠かすことができません。前者はデータベースを一から構築し、データをどのように扱い、どのように処理し、どのように加工するかといった設計を行います。



誰がデータを扱うのか

データベースアドミニストレーター

エンジニアは、データアーキテクトが作成したデータを元に、データの前処理を行い、データを使って分析をする準備を整えます。具体的には、欠損値の処理や、データの整理をすることによって、次の分析への橋渡しを行います。

データベースアドミニストレーターは、データベースに入るデータと出ていくデータをコントロールする仕事を担っていることができます。対象とするデータがビッグデータの場合、この処理は自動的に行われるようにすることが一般的です。

ですので、データベースアドミニストレーターは従来のデータを扱うことが一般的です。





過去を説明する
データサイエンス





ビジネス インテリジェンス


データを扱う方法は、大きく分けて二つの種類があります。一つは、過去に起こったことを説明するために使われること。そしてもう一つは、集めたデータをもとに、まだ起こっていない将来を予測するために使われることです。

データサイエンスの領域において将来の分析をする前には、過去の振る舞いを分析しなければいけません。過去のデータを分析し、そこから何らかの洞察を得て、それを将来の予測につなげていくのです。そして、ビジネスインテリジェンスはまさに過去から何らかの洞察を得る際に使われます。



ビジネス インテリジェンス

- どれだけの数が売れたのか？
- どのエリアで最も商品が売れたのか？
- どのタイプの商品が最も売れたのか？
- クリック率と収益の観点において、過去の四半期のメールマーケティングの成果はどうだったか？
- その結果は、一年前の同じ時期と比べてどうだったのか？



ビジネスインテリジェンスという言葉の中にはデータサイエンスという言葉は入っていませんが、ビジネスインテリジェンスはデータサイエンスを構成する要素となります。






BIアナリストは何をするのか

BIアナリストは 何をするのか？

データサイエンスが適用される領域には、ビジネス上の成果を図ることも含まれます。しかし、ビジネスインテリジェンスアナリストがそれを成し遂げるためには、データを適切に処理する能力が必要です。

データサイエンスにおけるスタート地点はデータです。データ（売上、販売量など）がビジネスインテリジェンスアナリストの手にわたると、彼らは

- データの定量化
 - KPIの計算
 - データからの洞察を得るための指標の設定
- などを行います。




BIアナリストが行うこと

データサイエンスは、ストーリーテリングとも言うこともできます。

厳密な量的データを扱うのとは別に、データサイエンス、とりわけビジネスインテリジェンスの領域においては、データを可視化し、解釈しやすい形にかみ砕いた表現にする必要があります。つまり、すべての職能の人が、同じ基準で判断を行うことができるような形で情報を整理しなければいけないのです。

BIアナリストは、グラフなどを使ったダッシュボードなどを作成し、今の美ビジネス上の目的に沿った形で資料を作成します。





BIはどこで使われるのか

価格の最適化

データサイエンスは、価格の最適化などに適用することが可能です。

そして、それはBIによって機能するのです。必要な情報がリアルタイムで収集され、そのデータが過去のデータと比較され、必要なアクションが即時に取られます。

ホテルの宿泊管理について考えてみましょう。多くの人が訪れる時期は、ホテルは宿泊費を上げ、その一方で需要が低い時期には、顧客を呼び込むために宿泊費を下げます。



在庫管理

データサイエンスとビジネスインテリジェンスは、在庫の調整においても活用されます。

どのように機能するのかというと、季節ごとの売り上げの変化などの過去の詳細なデータを活用することによって、どの時期にどれだけの在庫を抱えればよいのかといった判断を下すことができるようになり、結果として在庫コストを減らすことができます。





ビジネスインテリジェンスは誰が行うのか

ビジネス インテリジェンスの 職能

- ビジネスインテリジェンスアナリスト

BIアナリストは過去のデータを分析し、それを分かりやすい形でまとめることが主な仕事です

- ビジネスインテリジェンスデベロッパー

BIデベロッパーはPython、SQLといったより高度なプログラミングツールを使い、会社の定量分析のための資料を作成します。そういった意味では、需要がある重要なポジションの一つです。

ビジネス インテリジェンスの 職能

- ビジネスインテリジェンスコンサルタント

BIコンサルタントは外部のBIアナリストとすることができます。多くの会社はBIの仕事部分を外注しており、自社で人員を抱えていません。そういった意味では、BIコンサルタントはBIアナリストにもなりえますが、彼らは複数のプロジェクトにアサインされるという意味において、役割は多岐にわたります。すなわち、BIコンサルタントの職能は非常に多岐にわたるということです。ある意味、BIアナリストは特定の業務を進める人材である一方、BIコンサルタントは特定の業務に限定されないともいうことができるかもしれません。



将来を予測する データサイエンス





将来を予測する データサイエンス

データサイエンスにおける予測分析は過去のデータ分析に対する知見がどれだけあるかにかかっているとも言うことができます。

実際、予測分析と過去のデータ分析は緊密に関係しあっています。BIレポートやダッシュボードが作成され、データから必要な知見を抽出することができると、それが将来を予測する土台となります。そして、予測分析においては、どの手法を適用するかによって正確性が大きくかわってきます。

データサイエンスにおける従来のデータとビッグデータの違いを思い出してみましょう。これと同じような整理が、従来の統計学上の手法と機械学習の手法にも当てはめることができます。即ち、従来の統計学上の手法が従来のデータを主に対象とし、ビッグデータは機械学習の手法を対象にしています。

従来の手法

本ブックレットで言及している従来の手法というのは、古典的な統計学上の手法を示しており、線形回帰分析、ロジスティック回帰分析、クラスタリング、因子分析、時系列の分析といったものです。これらの分析結果は機械学習のより洗練されたアルゴリズムに適用されていきます。ここで、それらの手法について一つずつ見ていきましょう。

注記として、ある情報源では、今回ご紹介する手法が機械学習の手法として紹介されることがあります。しかし、本ブックレットでは、機械学習の手法はより新しく、洗練された手法を示します。



従来の手法

線形回帰

データサイエンスにおいては、線形回帰モデルは分析において使われる変数間の因果関係を定量化するために使われます。

家の価格と、床面積、近隣施設、築年数は相互に関係し合っているということが出来ます。そして、床面積などの情報があった場合に、家の価格を予想することができるようなモデルを構築することが線形回帰です。




従来の手法

ロジスティック回帰

変数間の関係が常に線形になるとは限りません。ロジスティック回帰などの手法は、データサイエンスにおいては非線形モデルとして活用されています。ロジスティック回帰は0か1が出力となります。


ロジスティック回帰を適用している企業は、採用の判断をする際の材料としてロジスティック回帰を使うことがあります。具体的には、ある応募者がその会社で活躍をする可能性が50%超であれば、その応募者を採用し、そうではなければ採用しない、という判断を行う場合などにおいて使われます。



従来の手法

クラスター分析

クラスター分析は、データがあるルールに従ってまとめることができそうな場合に力を発揮します。クラスター分析は、データ間の類似性を考慮し、そこからグループに新しい特徴を付与します。この特徴は、もとのデータからは読み取ることができない情報です。例えば、家のデータを見ていると、以下のようなクラスターに分けることができるかもしれません。①高価で床面積が狭い家(町の中央部にある家)。②広くて安い家(郊外の家)。③郊外で高い家(適度な都会にある大きな家)。




従来の手法

因子分析

クラスタリングが観測データをグループ分けすることだとすると、因子分析は特徴をまとめること、とすることができます。データサイエンスにおいては、因子分析は次元を削減するために使われます。


例えば、100個の質問があり、この100個の質問は10の考え方に整理できるとしましょう。因子分析はこれらの10の因子を特定することであり、因子分析をすることによって、回帰分析などの結果の解釈がより容易となります。データサイエンスにおいては、このように多くのテクニックが組み合わせられて使われることもあります。



従来の手法

級数解析

時系列は、ある期間における値を記録する一般的な手法です。時系列は、経済学やファイナンスの分野で良く使われています。とりわけ、株価とその取引量に関する情報などは経済学でもファイナンスでも使われます。この時、日時は常に横軸になり、他の変数に対して独立です。さらに、時系列としてプロットしたデータは、直線などによって表現することができます。その結果として、ある株が過去から現在において上がったのか、下がったのかということを直観的に把握することができます。





従来の予測手法 実生活での適用

従来の予測手法

User experience:

企業が何らかの商品を開発した際、顧客がその商品に対してどのような印象を抱いているかという点に対する調査が行われることがあります。そしてBIチームによって行われた分析結果によって、データをセグメントに分けた上で、それぞれのセグメントから有意な特徴が抽出されます。その結果、このような分析を行うことによって、それぞれのセグメントに対してどのような対策を取っていけば良いのかといったことが分かり、その結果としてそれが顧客満足度の向上につながっていきます。



従来の予測手法

Forecasting sales:

時系列が関係しているとき、過去だけではなく、将来の売り上げ予測も分析の対象となります。この時、次の期間においてこういったことが予想されるのかという結論をデータサイエンティストが分析できるようになるまで、販売に関する情報が収集されることとなります。データサイエンティストは、数学や統計学上の手法を用いて数多くのシミュレーションを行います。その結果としていくつかの予測を立てることができですが、この予測に基づいて会社が意思決定をするという意味では、データサイエンスにおける中心的な業務ということもできます。





従来の予測手法を用いるのは誰か

従来の予測手法を用いるのは誰か

上記の質問の答えはデータサイエンティストとなりますが、データサイエンティストは分析において、機械学習のテクニックを用いることもある点を意識しておきましょう。つまり、一つの分野の考え方が相互に関連しあっているのです。

その一方、データアナリストは、過去にすでに起こった事象をもとにデータを分析し、データの中からより高度な法則性などを見出す人のことを言います。



機械学習

機械学習はデータサイエンスと非常に親和性が高い考え方です。

機械学習が従来のデータサイエンスと親和性が高い理由として、その本質部分がアルゴリズムとして整理されているという点が挙げられます。そのアルゴリズムによって、データに対して最も当てはまりが良いモデルを作成することができるようになるのです。

統計の手法と比べて優れている点、すなわち、機械学習と従来のデータサイエンスの手法の違いは、人が明示的に分析の方向性を出さないといということです。つまり、アルゴリズムが自ら学び、最適なモデルを作成するということです。つまり、従来の手法と比べて人の関与が最小となるのです。


実際、機械学習の中でもディープラーニングのアルゴリズムは非常に複雑であり、内部で何が行われているか人が理解することはできません。

機械学習のアルゴリズム

機械学習のアルゴリズムは試行錯誤のプロセスということもできますが、その中の特徴として、それぞれの連続する試行においては、その前の試行よりも良くなっているということが挙げられます。ですが、よりよく学習をさせるためには、機械は数百回、数千回という単位で、試行錯誤を繰り返す必要があります。そして、繰り返し試行錯誤を行うごとに、誤差の値を小さくしていきます。

そして、学習が終わると、モデルが作成されます。そのモデルにデータを入れることによって、値を予測することができるようになります。

機械学習には、大きく三つの種類があります。一つ目が教師あり学習、もう一つが教師なし学習。そして最後が強化学習です。



教師あり学習

教師あり学習では、ラベル付けされたデータを扱います。ここで、膨大なビデオデータと画像があり、それらに犬、猫、その他というラベル付けがされているとしましょう。

そして、機械は入力データとラベル付けされたデータが同時に入力されます。機械が出力した結果と実際の結果が異なっていれば、最適化アルゴリズムが働き、その上で改めてデータが入って内部で演算が行われます。実際には、機械は一度に非常に多くのデータでこの処理を行っていきます。

ニューラルネットワーク、ディープラーニング、ランダムフォレストなどはいずれも教師あり学習として適用することができます。

教師なし学習

データの量があまりにも多い場合や、データサイエンティストがラベル付けをする余裕がない場合、もしくは、つけるべきラベルの全体像が分からない場合などは、データサイエンティストは教師なし学習を使います。教師なし学習は機械に対してラベル付けされていないデータ渡し、そこから何らかの洞察を抽出するようにさせます。その結果、データの特徴をもとにして、データのグループ分けが行われます。違う表現をすると、クラスターに分けるということができます。


教師なし学習は、とりわけデータからあるパターンを抽出したい時や、人間によって従来の手法を適用した場合に間違いが起こる可能性がある場合などに用いられます。



強化学習

強化学習は、正確性ではなく、歩く、見る、読むといった行動に焦点が当てられています。機械が前よりも良いパフォーマンスを発揮できたのであれば、報酬を受け取り、パフォーマンスが下回るようであれば、値の修正は行わなければならないということになります。

ここで、犬がある命令を覚える場合について考えてみましょう。犬が命令に従ったらご褒美をあげて、従わなかったらご褒美はあげないという形で訓練をしていくことになります。そして、犬はご褒美をもらうために命令をどんどん覚えていくことになります。これが、強化学習は損失を最小化するのではなく、報酬を最大化すると言われるゆえんです。



機械学習

実生活への応用

機械学習が 使われる場面

詐欺の検知:


ここから、機械学習が実際に使われる場面についてお伝えしていきます。例えば、銀行は過去の取引情報をデータにし、そのデータを正常な取引データと詐欺の取引データに分類します。そして、そのデータをもとに、詐欺の取引を見つけるためのモデルを作成します。結果として、数多くの取引の中で詐欺の取引の数が非常に小さいとしても、モデルはリアルタイムで詐欺の取引を見分けることができますようになります。



機械学習が 使われる場面

顧客の維持:

機械学習のアルゴリズムを使うことによって、企業はどの顧客が商品を買う可能性があるかを予測することができるようになります。そして、顧客の購買可能性が予測できるようになることによって、お店は割引のオファーをしたり、特定の人に向けたキャンペーンを最小のコストによって行うことができ、結果として収益の最大化につなげることができます。この技術をうまく使っている企業がGoogleやAmazonです。






機械学習を使うのは誰か

誰が機械学習を使うのか

既にお伝えしてきた通り、データサイエンティストは機械学習と密接なかかわりを持っています。ですが、ここではそれ以外の職業についてご紹介していきます。

機械学習エンジニアは、非常に煩雑な演算モデルを適用して機械学習のアルゴリズムを作成し、ビジネス上の課題、データサイエンス上の課題、コンピュータービジョン、自動運転、ロボティクスといった分野の問題を解決することを職能としています。





プログラミング言語
とソフトウェア

プログラミング言語

プログラミング言語を知ることによって、データサイエンティストは特定の課題に対処するプログラムを組むことができるようになります。プログラミング言語が有する最大の強みは、その柔軟性です。

RとPythonとMATLABは、SQLと組み合わせることによって、従来のデータ、BI、データサイエンスの領域において使われるツールとして十分な力を発揮します。


RとPythonは、データサイエンスの領域において最も良く使われているプログラミング言語です。この二つの言語の最大の強みは、データを柔軟に扱うことができ、それをデータサイエンスにおいて用いられる複数のツールで活用できることです。そして、この二つは、演算を行うだけでなく、統計量を求めることもできます。



プログラミング言語

リレーショナルデータベースマネジメントシステムという観点においては、SQLが最上に位置すると言えます。なぜなら、SQLはデータを扱うことに特化したシステムだからです。特に、SQLは従来のデータ、過去のデータを整理するBIの分野において力を発揮します。

MATLABもデータサイエンスの領域においてよく使われるツールの一つです。MATLABは数学の関数や、行列の演算を行う際に優れた力を発揮します。





プログラミング言語

データサイエンスにおけるビッグデータは、RとPythonを使うことによって上手に活用されます。ですが、この領域で業務を行っている人にとっては、JavaやScalaといった言語に長けているかもしれません。この二つの言語は、多くの情報源から情報を取得し、整理をする上で強みを発揮する言語です。

JavaScript、C、C++はデータサイエンスの中の特定の領域において用いられることが多いようです。これらの言語は、処理速度が速く、コードの柔軟性も有しています。



ソフトウェアと フレームワーク

データサイエンスにおいて、ソフトウェアは特定のビジネス上のニーズに応じて活用されます。

エクセルは一つのカテゴリにおいて用いられるだけでなく、従来のデータ、BI、データサイエンスにおいて使われます。同様に、SPSSは従来のデータや統計分析において良く使われるツールです。

TensorFlowは機械学習のアルゴリズムの中で、とりわけビッグデータを対象として作られたツールです。TensorFlowはGoogleによって開発され、2015年に一般公開されました。そして、今日、ニューラルネットワークを使った分析においては、最も良く使われるツールとなっています。



ソフトウェアと フレームワーク

Apache Hadoop、Apache HbaseとMongo DBはビッグデータを扱うために設計されたソフトウェアです。

Power BI、SaS、QlikとTableauはビジネスインテリジェンスにおけるデータの可視化において非常に良く使われるツールです。

予測分析という観点においては、Eviewsが時系列のデータの分析などにおいて非常によく使われるソフトウェアです。そして、Stataは学術向けのソフトウェアであり、学術論文における回帰、クラスタリング、因子分析などにおいて用いられています。





FAQ



面接において 良く聞かれる質問

1. データサイエンスが意味するものは？
2. 線形回帰における想定は？
3. 因子分析とクラスター分析の違いは？
4. Iteratorとは何か
5. 2つのテーブルからデータを取得するSQL文を書きなさい
6. クリック率とチケットの売り上げの関係をまとめたグラフを描きなさい
7. 技術的な背景がない人に対して、ランダムフォレストをどうやって説明しますか？
8. モデルの中身が改善されたことを、どうやって説明しますか？
9. 根本原因解析とは何ですか？



面接において良く聞かれる質問

10. K近傍法について説明しなさい
11. リレーショナルデータベースマネジメントシステムに関し、どのような経験がありますか？
12. 教師あり学習と教師なし学習の違いは？
13. 過学習とは？そして、それをどのように解決しますか？
14. SQL、MySQLとSQL Serverの違いは？
15. ビッグデータのデータクリーニングをどのように行いますか？
16. false negativeがfalse positiveよりも重要ということ、一つ例を挙げて説明しなさい
17. データベースのデータの整理をする中で起こりがちなバイアスについて説明しなさい
18. ロジスティック回帰とは何ですか？





Good luck!